```
In [1]: import numpy as np
         import pandas as pd
In [2]: train = pd.read csv('https://bit.ly/fc-ml-titanic')
In [3]: train.head()
Out[3]:
            PassengerId Survived Pclass
                                                                         Sex Age SibSp Parch
                                                                                                         Ticket
                                                                                                                   Fare Cabin Embarked
                                                               Name
                                0
                                               Braund, Mr. Owen Harris
                                                                        male 22.0
                                                                                                     A/5 21171
                                                                                                                 7.2500
                                                                                                                          NaN
                                                                                                                                        S
         0
                      1
                                       3
                                                                                               0
                                             Cumings, Mrs. John Bradley
                      2
                                                                                                                                        C
         1
                                1
                                                                      female 38.0
                                                                                        1
                                                                                              0
                                                                                                      PC 17599 71.2833
                                                                                                                           C85
                                                   (Florence Briggs Th...
                                                                                                      STON/O2.
                      3
                                                                                                                 7.9250
         2
                                       3
                                                 Heikkinen, Miss. Laina female 26.0
                                                                                              0
                                                                                                                          NaN
                                                                                                                                        S
                                1
                                                                                        0
                                                                                                       3101282
                                            Futrelle, Mrs. Jacques Heath
         3
                                                                      female 35.0
                                                                                                                                        S
                      4
                                1
                                                                                        1
                                                                                              0
                                                                                                        113803 53.1000
                                                                                                                          C123
                                                        (Lily May Peel)
                                               Allen, Mr. William Henry
                      5
                                0
                                                                                                        373450
                                                                                                                 8.0500
                                                                                                                                        S
         4
                                       3
                                                                        male 35.0
                                                                                        0
                                                                                               0
                                                                                                                          NaN
```

데이터 셋: 타이타닉 데이터셋 (출처: Kaggle.com)

In [5]: train.head()

Out[5]:		PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
	0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
	1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th	female	38.0	1	0	PC 17599	71.2833	C85	С
	2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
	3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
	4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

• Passengerld: 승객 아이디

• Survived: 생존 여부, 1: 생존, 0: 사망

Pclass: 등급Name: 성함

• Sex: 성별

• Age: 나이

• SibSp: 형제, 자매, 배우자 수

• Parch: 부모, 자식 수

• Ticket: 티켓번호

• Fare: 요즘

• Cabin: 좌석번호

• Embarked: 탑승 항구

전처리: train / validation 세트 나누기

- 1. 먼저, feature 와 label을 정의합니다.
- 2. feature / label을 정의했으면, 적절한 비율로 train / validation set을 나눕니다.

```
In [9]: feature = [
             'Pclass', 'Sex', 'Age', 'Fare'
In [10]: label = [
             'Survived'
In [11]: train[feature].head()
Out[11]:
           Pclass
                    Sex Age
                                 Fare
         0
               3 male 22.0 7.2500
               1 female 38.0 71.2833
         2
               3 female 26.0 7.9250
               1 female 35.0 53.1000
         4
               3 male 35.0 8.0500
In [12]: train[label].head()
Out[12]:
           Survived
         0
                  0
         2
         3
         4
                  0
In [13]: from sklearn.model_selection import train_test_split
```

```
• test_size: validation set에 할당할 비율 (20% -> 0.2)
```

• shuffle: 셔플 옵션 (기본 True)

• random_state: 랜덤 시드값

return받는 데이터의 순서가 중요합니다.

전처리: 결측치

```
In [20]: train.info()
```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):

#	Column	Non-Null Count	Dtype				
0	PassengerId	891 non-null	int64				
1	Survived	891 non-null	int64				
2	Pclass	891 non-null	int64				
3	Name	891 non-null	object				
4	Sex	891 non-null	object				
5	Age	714 non-null	float64				
6	SibSp	891 non-null	int64				
7	Parch	891 non-null	int64				
8	Ticket	891 non-null	object				
9	Fare	891 non-null	float64				
10	Cabin	204 non-null	object				
11	Embarked	889 non-null	object				
<pre>dtypes: float64(2), int64(5), object(5)</pre>							
memory usage: 83.7+ KB							

결측치를 확인하는 방법은 pandas의 isnull()

그리고 합계를 구하는 sum()을 통해 한 눈에 확인할 수 있습니다.

```
In [22]: train.isnull().sum()
```

Out[22]: PassengerId 0 Survived 0 Pclass 0 Name 0 Sex 0 Age 177 SibSp 0 Parch 0 Ticket 0 Fare 0 Cabin 687 Embarked 2 dtype: int64

개별 column의 결측치에 대하여 확인하는 방법은 다음과 같습니다.

In [24]: train['Age'].isnull().sum()

```
Out[24]: 177
        Impute 도큐먼트
        1. 수치형 (Numerical Column) 데이터에 대한 결측치 처리
In [27]: train['Age'].fillna(0).describe()
Out[27]:
         count
                 891.000000
                  23.799293
         mean
         std
                  17.596074
                   0.000000
         min
         25%
                   6.000000
         50%
                  24.000000
         75%
                  35.000000
                  80.000000
         max
         Name: Age, dtype: float64
In [28]: train['Age'].fillna(train['Age'].mean()).describe()
Out[28]: count
                 891.000000
                  29.699118
         mean
         std
                  13.002015
                  0.420000
         min
         25%
                  22.000000
         50%
                  29.699118
         75%
                  35.000000
                  80.000000
         max
         Name: Age, dtype: float64
        imputer: 2개 이상의 column을 한 번에 처리할 때
In [30]: from sklearn.impute import SimpleImputer
```

```
In [31]: imputer = SimpleImputer(strategy='mean')
        fit() 을 통해 결측치에 대한 학습을 진행합니다.
In [33]: imputer.fit(train[['Age', 'Pclass']])
Out[33]:
            SimpleImputer
        SimpleImputer()
        transform() 은 실제 결측치에 대한 처리를 해주는 함수합니다.
In [35]: result = imputer.transform(train[['Age', 'Pclass']])
In [36]: result
Out[36]: array([[22.
                [38.
                           , 1.
                [26.
                           , 3.
               [29.69911765, 3.
                          , 1.
                [26.
                [32.
                           , 3.
                                       ]])
In [37]: train[['Age', 'Pclass']] = result
In [38]: train[['Age', 'Pclass']].isnull().sum()
Out[38]: Age
                  0
         Pclass
         dtype: int64
In [39]: train[['Age', 'Pclass']].describe()
```

Out[39]:		Age	Pclass
	count	891.000000	891.000000
	mean	29.699118	2.308642
	std	13.002015	0.836071
	min	0.420000	1.000000
	25%	22.000000	2.000000
	50%	29.699118	3.000000
	75%	35.000000	3.000000
	max	80.000000	3.000000

fit_transform()은 fit()과 transform()을 한 번에 해주는 함수 입니다.

```
In [47]: train[['Age', 'Pclass']].describe()
Out[47]:
                                Pclass
                      Age
          count 891.000000 891.000000
                 29.361582
                              2.308642
          mean
                 13.019697
                              0.836071
            std
                  0.420000
                              1.000000
           min
                 22.000000
           25%
                              2.000000
           50%
                 28.000000
                              3.000000
           75%
                 35.000000
                              3.000000
                 80.000000
                              3.000000
           max
```

2. (Categorical Column) 데이터에 대한 결측치 처리

```
In [49]: train = pd.read_csv('https://bit.ly/fc-ml-titanic')
1개의 column을 처리하는 경우
In [51]: train['Embarked'].fillna('S')
```

```
Out[51]: 0
                S
         2
                S
         886
                S
                S
         887
                S
         888
         889
         890
         Name: Embarked, Length: 891, dtype: object
         Imputer를 사용하는 경우: 2개 이상의 column을 처리할 때
In [53]: imputer = SimpleImputer(strategy='most frequent')
In [54]: result = imputer.fit transform(train[['Embarked', 'Cabin']])
In [55]: train[['Embarked', 'Cabin']] = result
In [56]: train[['Embarked', 'Cabin']].isnull().sum()
Out[56]:
         Embarked
         Cabin
         dtype: int64
```

Label Encoding : 문자(categorical)를 수치(numerical)로 변환

학습을 위해서 모든 문자로된 **데이터는 수치로 변환**하여야 합니다.

```
In [59]: train.info()
```

```
<class 'pandas.core.frame.DataFrame'>
        RangeIndex: 891 entries, 0 to 890
        Data columns (total 12 columns):
             Column
                         Non-Null Count Dtype
             PassengerId 891 non-null
                                          int64
             Survived
                         891 non-null
                                         int64
             Pclass
                          891 non-null
                                         int64
                                         object
         3
             Name
                          891 non-null
         4
             Sex
                         891 non-null
                                         object
             Age
                          714 non-null
                                         float64
         6
             SibSp
                          891 non-null
                                         int64
         7
                         891 non-null
             Parch
                                         int64
             Ticket
                         891 non-null
                                         object
             Fare
                          891 non-null
                                         float64
         10 Cabin
                         891 non-null
                                         object
         11 Embarked
                         891 non-null
                                         object
        dtypes: float64(2), int64(5), object(5)
        memory usage: 83.7+ KB
In [60]: def convert(data):
             if data == 'male':
                 return 1
             elif data == 'female':
                 return 0
In [61]: train['Sex'].value_counts()
Out[61]: Sex
          male
                   577
          female
                   314
         Name: count, dtype: int64
In [62]: train['Sex'].apply(convert)
```

```
Out[62]: 0
         2
                0
                1
         886
                1
         887
         888
         889
         890
         Name: Sex, Length: 891, dtype: int64
In [63]: from sklearn.preprocessing import LabelEncoder
In [64]: le = LabelEncoder()
In [65]: train['Sex num'] = le.fit transform(train['Sex'])
In [66]: train['Sex num'].value counts()
Out[66]: Sex num
              577
              314
         Name: count, dtype: int64
In [67]: le.classes_
Out[67]: array(['female', 'male'], dtype=object)
In [68]: le.inverse_transform([0, 1, 1, 0, 0, 1, 1])
Out[68]: array(['female', 'male', 'female', 'female', 'male', 'male'],
               dtype=object)
         NaN 값이 포함되어 있다면, LabelEncoder 가 정상 동작하지 않습니다.
In [70]: le.fit_transform(train['Embarked'])
```

Out[70]: array([2, 0, 2, 2, 2, 1, 2, 2, 2, 0, 2, 2, 2, 2, 2, 2, 1, 2, 2, 0, 2, 2, 1, 2, 2, 2, 0, 2, 1, 2, 0, 0, 1, 2, 0, 2, 0, 2, 2, 0, 2, 2, 0, 0, 1, 2, 1, 1, 0, 2, 2, 2, 0, 2, 0, 2, 2, 0, 2, 2, 0, 2, 2, 2, 0, 0, 2, 2, 2, 2, 2, 2, 0, 2, 2, 2, 2, 2, 2, 2, 1, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 0, 0, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 1, 2, 0, 2, 2, 0, 2, 1, 2, 0, 2, 2, 0, 2, 2, 0, 1, 2, 0, 2, 0, 2, 2, 2, 2, 0, 2, 2, 2, 0, 0, 2, 2, 1, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 0, 2, 2, 2, 0, 2, 2, 2, 1, 2, 1, 2, 2, 2, 2, 2, 0, 0, 1, 2, 1, 2, 2, 2, 2, 0, 2, 2, 2, 0, 1, 0, 2, 2, 2, 2, 1, 0, 2, 2, 0, 2, 2, 2, 0, 1, 2, 2, 2, 2, 2, 2, 2, 2, 0, 0, 2, 0, 2, 1, 2, 2, 2, 1, 2, 2, 2, 2, 2, 2, 2, 2, 0, 1, 2, 2, 2, 1, 2, 1, 2, 2, 2, 2, 0, 2, 2, 2, 1, 2, 0, 0, 2, 2, 0, 0, 2, 2, 0, 1, 1, 2, 1, 2, 2, 0, 0, 0, 0, 0, 0, 2, 2, 2, 2, 2, 2, 0, 2, 2, 1, 2, 2, 0, 2, 2, 2, 0, 0, 2, 0, 2, 2, 2, 1, 1, 2, 0, 0, 2, 1, 2, 0, 0, 1, 0, 0, 2, 2, 0, 2, 0, 2, 0, 0, 2, 0, 0, 2, 2, 2, 2, 2, 1, 0, 2, 2, 2, 0, 2, 2, 2, 2, 2, 2, 2, 2, 2, 0, 2, 2, 2, 0, 0, 2, 0, 2, 2, 2, 1, 2, 2, 2, 2, 2, 2, 2, 1, 0, 2, 2, 2, 0, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 0, 2, 2, 0, 2, 2, 2, 2, 2, 0, 2, 0, 0, 2, 2, 2, 2, 1, 1, 2, 2, 0, 2, 2, 2, 2, 1, 2, 2, 0, 2, 2, 2, 1, 2, 2, 2, 2, 0, 0, 0, 1, 2, 2, 2, 2, 2, 0, 0, 0, 2, 2, 2, 0, 2, 0, 2, 2, 2, 2, 0, 2, 2, 0, 2, 2, 0, 2, 1, 0, 2, 2, 0, 0, 2, 2, 1, 2, 2, 2, 2, 2, 2, 2, 2, 0, 2, 2, 2, 2, 1, 2, 2, 2, 0, 2, 2, 0, 2, 0, 0, 2, 2, 0, 2, 2, 2, 0, 2, 1, 2, 2, 2, 0, 0, 2, 2, 2, 0, 2, 2, 2, 0, 2, 2, 2, 1, 1, 2, 2, 2, 2, 2, 0, 2, 0, 2, 2, 2, 1, 2, 2, 1, 2, 2, 0, 2, 2, 2, 2, 2, 2, 2, 2, 0, 2, 2, 0, 0, 2, 0, 2, 2, 2, 2, 1, 1, 2, 2, 1, 2, 0, 2, 2, 2, 0, 2, 2, 2, 2, 2, 0, 2, 0, 2, 2, 2, 1, 0, 2, 0, 2, 0, 1, 2, 2, 2, 2, 2, 0, 0, 2, 2, 2, 2, 0, 2, 1, 2, 2, 2, 2, 2, 2, 2, 2, 1, 2, 2, 2, 0, 2, 2, 2, 2, 0, 2, 2, 2, 2, 0, 2, 2, 2, 2, 2, 2, 1, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 0, 2, 2, 2, 0, 1, 1, 2, 2, 2, 2, 0, 2, 2, 1, 2, 1, 2, 0, 2, 2, 2, 2, 2, 2, 1, 2, 0, 1, 2, 2, 2, 2, 0, 2, 2, 2, 2, 2, 2, 1, 2, 0, 1, 2, 0, 2, 0, 2, 2, 0, 2, 2, 2, 0, 2, 2, 0, 0, 2, 2, 2, 0, 2, 0, 2, 2, 0, 2, 2, 2, 2, 2,

Out[72]: array([2, 0, 2, 2, 2, 1, 2, 2, 2, 0, 2, 2, 2, 2, 2, 2, 1, 2, 2, 0, 2, 2, 1, 2, 2, 2, 0, 2, 1, 2, 0, 0, 1, 2, 0, 2, 0, 2, 2, 0, 2, 2, 0, 0, 1, 2, 1, 1, 0, 2, 2, 2, 0, 2, 0, 2, 2, 0, 2, 2, 0, 2, 2, 2, 0, 0, 2, 2, 2, 2, 2, 2, 0, 2, 2, 2, 2, 2, 2, 2, 1, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 0, 0, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 1, 2, 0, 2, 2, 0, 2, 1, 2, 0, 2, 2, 0, 2, 2, 0, 1, 2, 0, 2, 0, 2, 2, 2, 2, 0, 2, 2, 2, 0, 0, 2, 2, 1, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 0, 2, 2, 2, 0, 2, 2, 2, 1, 2, 1, 2, 2, 2, 2, 2, 0, 0, 1, 2, 1, 2, 2, 2, 2, 0, 2, 2, 2, 0, 1, 0, 2, 2, 2, 2, 1, 0, 2, 2, 0, 2, 2, 2, 0, 1, 2, 2, 2, 2, 2, 2, 2, 2, 0, 0, 2, 0, 2, 1, 2, 2, 2, 1, 2, 2, 2, 2, 2, 2, 2, 2, 0, 1, 2, 2, 2, 1, 2, 1, 2, 2, 2, 2, 0, 2, 2, 2, 1, 2, 0, 0, 2, 2, 0, 0, 2, 2, 0, 1, 1, 2, 1, 2, 2, 0, 0, 0, 0, 0, 0, 2, 2, 2, 2, 2, 2, 0, 2, 2, 1, 2, 2, 0, 2, 2, 2, 0, 0, 2, 0, 2, 2, 2, 1, 1, 2, 0, 0, 2, 1, 2, 0, 0, 1, 0, 0, 2, 2, 0, 2, 0, 2, 0, 0, 2, 0, 0, 2, 2, 2, 2, 2, 1, 0, 2, 2, 2, 0, 2, 2, 2, 2, 2, 2, 2, 2, 2, 0, 2, 2, 2, 0, 0, 2, 0, 2, 2, 2, 1, 2, 2, 2, 2, 2, 2, 2, 1, 0, 2, 2, 2, 0, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 0, 2, 2, 0, 2, 2, 2, 2, 2, 0, 2, 0, 0, 2, 2, 2, 2, 1, 1, 2, 2, 0, 2, 2, 2, 2, 1, 2, 2, 0, 2, 2, 2, 1, 2, 2, 2, 2, 0, 0, 0, 1, 2, 2, 2, 2, 2, 0, 0, 0, 2, 2, 2, 0, 2, 0, 2, 2, 2, 2, 0, 2, 2, 0, 2, 2, 0, 2, 1, 0, 2, 2, 0, 0, 2, 2, 1, 2, 2, 2, 2, 2, 2, 2, 2, 0, 2, 2, 2, 2, 1, 2, 2, 2, 0, 2, 2, 0, 2, 0, 0, 2, 2, 0, 2, 2, 2, 0, 2, 1, 2, 2, 2, 0, 0, 2, 2, 2, 0, 2, 2, 2, 0, 2, 2, 2, 1, 1, 2, 2, 2, 2, 2, 0, 2, 0, 2, 2, 2, 1, 2, 2, 1, 2, 2, 0, 2, 2, 2, 2, 2, 2, 2, 2, 0, 2, 2, 0, 0, 2, 0, 2, 2, 2, 2, 1, 1, 2, 2, 1, 2, 0, 2, 2, 2, 0, 2, 2, 2, 2, 2, 0, 2, 0, 2, 2, 2, 1, 0, 2, 0, 2, 0, 1, 2, 2, 2, 2, 2, 0, 0, 2, 2, 2, 2, 0, 2, 1, 2, 2, 2, 2, 2, 2, 2, 2, 1, 2, 2, 2, 0, 2, 2, 2, 2, 0, 2, 2, 2, 2, 0, 2, 2, 2, 2, 2, 2, 1, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 0, 2, 2, 2, 0, 1, 1, 2, 2, 2, 2, 0, 2, 2, 1, 2, 1, 2, 0, 2, 2, 2, 2, 2, 2, 1, 2, 0, 1, 2, 2, 2, 2, 0, 2, 2, 2, 2, 2, 2, 1, 2, 0, 1, 2, 0, 2, 0, 2, 2, 0, 2, 2, 2, 0, 2, 2, 0, 0, 2, 2, 2, 0, 2, 0, 2, 2, 0, 2, 2, 2, 2, 2,

```
0, 0, 2, 2, 2, 2, 2, 0, 2, 2, 2, 2, 2, 2, 0, 0, 2, 2, 2, 0, 0, 2, 2, 2, 0, 2, 2, 2, 2, 2, 1, 2, 2, 2, 0, 1])
```

원 핫 인코딩 (One Hot Encoding)

```
In [74]: train = pd.read csv('https://bit.ly/fc-ml-titanic')
In [75]: train.head()
Out[75]:
             PassengerId Survived Pclass
                                                                         Sex Age SibSp Parch
                                                                                                                  Fare Cabin Embarked
                                                               Name
                                                                                                        Ticket
          0
                      1
                                       3
                                               Braund, Mr. Owen Harris
                                                                        male 22.0
                                                                                              0
                                                                                                    A/5 21171
                                                                                                                7.2500
                                                                                                                                       S
                                                                                                                         NaN
                                             Cumings, Mrs. John Bradley
                      2
                                                                      female 38.0
                                                                                                     PC 17599 71.2833
         1
                                1
                                                                                              0
                                                                                                                                       C
                                                                                       1
                                                                                                                         C85
                                                   (Florence Briggs Th...
                                                                                                     STON/O2.
          2
                      3
                                1
                                       3
                                                 Heikkinen, Miss. Laina female 26.0
                                                                                       0
                                                                                              0
                                                                                                                7.9250
                                                                                                                                       S
                                                                                                                         NaN
                                                                                                      3101282
                                            Futrelle, Mrs. Jacques Heath
                                                                      female 35.0
                                                                                                                                       S
          3
                                                                                              0
                                                                                                       113803 53.1000
                                                                                       1
                                                                                                                        C123
                                                        (Lily May Peel)
                      5
                                                Allen, Mr. William Henry
                                                                                                       373450
                                                                                                                8.0500
          4
                                0
                                       3
                                                                       male 35.0
                                                                                       0
                                                                                              0
                                                                                                                                       S
                                                                                                                         NaN
          Embarked 를 살펴봅시다
         train['Embarked'].value counts()
Out[77]: Embarked
               644
               168
                77
          Name: count, dtype: int64
In [78]: train['Embarked'] = train['Embarked'].fillna('S')
In [79]: train['Embarked'].value counts()
```

```
Out[79]: Embarked
            646
            168
             77
        Name: count, dtype: int64
In [80]: train['Embarked num'] = LabelEncoder().fit transform(train['Embarked'])
In [81]: train['Embarked num'].value counts()
Out[81]: Embarked num
            646
            168
            77
        Name: count, dtype: int64
       Embarked는 탑승 항구의 이니셜을 나타냈습니다.
       그런데, 우리는 이전에 배운 내용처럼 LabelEncoder 를 통해서 수치형으로 변환해주었습니다.
       하지만, 이대로 데이터를 기계학습을 시키면, 기계는 데이터 안에서 관계를 학습합니다.
       즉, 'S' = 2, 'Q' = 1 이라고 되어 있는데, Q + Q = S 가 된다 라고 학습해버린다는 것이죠.
       그렇기 때문에, 독립적인 데이터는 별도의 column으로 분리하고, 각각의 컬럼에 해당 값에만 True 나머지는 False를 갖습니다. 우리는 이것
       은 원 핫 인코딩 한다라고 합니다.
In [84]: train['Embarked'][:6]
Out[84]: 0
            C
            S
        3
            S
            S
        Name: Embarked, dtype: object
In [85]: train['Embarked num'][:6]
```

```
Out[85]: 0
              2
              0
          2
              2
              2
          Name: Embarked_num, dtype: int32
         pd.get_dummies(train['Embarked_num'][:6]).astype(int)
In [195...
Out[195...
            0 1 2
         0 0 0 1
         1 1 0 0
          2 0 0 1
          3 0 0 1
          4 0 0 1
          5 0 1 0
In [87]: one_hot = pd.get_dummies(train['Embarked_num'][:6])
In [88]: one_hot.columns = ['C','Q','S']
In [197... one_hot.astype(int)
```

```
Out[197...

C Q S

0 0 0 1

1 1 0 0

2 0 0 1

3 0 0 1

4 0 0 1

5 0 1 0
```

위와 같이 column 을 분리시켜 **카테고리형 -> 수치형으로 변환**하면서 생기는 수치형 값 의 관계를 끊어주어서 독립적인 형태로 바꾸어 줍니다.

원핫인코딩은 카테고리 (계절, 항구, 성별, 종류, 한식/일식/중식...)의 특성을 가지는 column에 대해서 적용 합니다.

전처리: Normalize (정규화)

column 간에 다른 min, max 값을 가지는 경우, 정규화를 통해 최소치/ 최대값의 척도를 맞추어 주는 것

- 네이버 영화평점 (0점 ~ 10점): [2, 4, 6, 8, 10]
- 넷플릭스 영화평점 (0점 ~ 5점): [1, 2, 3, 4, 5]

```
Out[96]:
             naver netflix
           0
                         2
           2
                 6
                         3
           4
                10
                         5
In [97]: from sklearn.preprocessing import MinMaxScaler
In [98]: min max scaler = MinMaxScaler()
In [99]: min_max_movie = min_max_scaler.fit_transform(movie)
In [100...
          pd.DataFrame(min_max_movie, columns=['naver', 'netflix'])
Out[100...
             naver netflix
              0.00
                      0.00
               0.25
                      0.25
               0.50
                      0.50
              0.75
                      0.75
              1.00
                      1.00
```

표준화 (Standard Scaling)

평균이 0과 표준편차가 1이 되도록 변환

In [103... **from** sklearn.preprocessing **import** StandardScaler

```
standard scaler = StandardScaler()
          샘플데이터를 생성합니다.
In [105...
         x = np.arange(10)
          # outlier 추가
          x[9] = 1000
In [106...
         x.mean(), x.std()
Out[106... (103.6, 298.8100399919654)
In [107... scaled = standard_scaler.fit_transform(x.reshape(-1, 1))
         x.mean(), x.std()
In [108...
Out[108...
          (103.6, 298.8100399919654)
         scaled.mean(), scaled.std()
In [109...
Out[109... (4.4408920985006264e-17, 1.0)
In [110...
         round(scaled.mean(), 2), scaled.std()
Out[110... (0.0, 1.0)
  In [ ]:
  In [ ]:
```